Experimentos de algoritmos

Reporte final: aceleración paralela, mochila voraz, búsqueda local 2-opt, recocido simulado y aproximación MST para el TSP.

Alumno: ESCRIBE TU NOMBRE

Materia: Analisis de Algoritmos

Repositorio público: PEGAR_AQUI_URL_PUBLICA_GITHUB

Video demostrativo: PEGAR_AQUI_ENLACE_VIDEO

Resumen y metodología

Se implementaron los cinco experimentos en Python. Se usaron semillas fijas para la reproducibilidad, mediciones con **time.perf_counter()** y conjuntos de prueba compartidos cuando fue necesario comparar métodos. Las tablas y figuras siguientes se generan automáticamente a partir de ejecuciones reales; no se introdujeron valores manualmente.

El problema del agente viajero (TSP) se modeló con distancias euclidianas bidimensionales. El costo incluye el regreso a la ciudad de inicio. Cada ruta contiene cada ciudad exactamente una vez. En las pruebas de nueve ciudades se calculó el óptimo global exacto con programación dinámica Held-Karp.

1. Aceleración paralela: Monte Carlo para π

Se estimó π usando 3,000,000 puntos uniformes dentro del cuadrado unitario y 3 repeticiones independientes para cada configuración: 1, 2, 4 y 8 procesos. El número total de puntos se mantuvo fijo. Se midió el tiempo de pared y se tomó la mediana; la aceleración se calculó como S(p) = T(1) / T(p).

Procesos	Tiempo mediano (s)	Speedup real	Speedup ideal
1	2.331	1.00	1
2	4.811	0.48	2
4	3.041	0.77	4
8	4.304	0.54	8

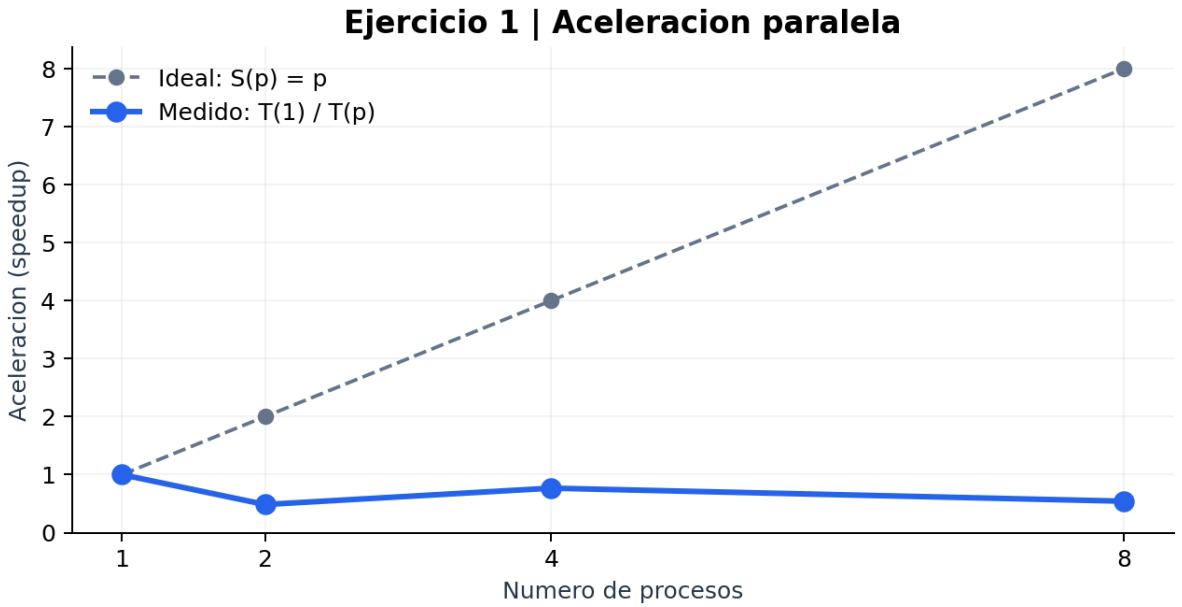


Figura 1. Aceleración medida comparada con el aumento ideal lineal.

Análisis: con ocho procesos se observó una aceleración de 0.54× (ideal: 8×; eficiencia: 6.8%). No se espera escalado perfecto porque crear procesos, repartir trabajo y reunir resultados agrega sobrecostos; la CPU y el ancho de banda de memoria también se comparten. La ley de Amdahl establece que la fracción no paralelizable limita la aceleración máxima. Con trabajos relativamente pequeños, los costos fijos pueden incluso provocar desaceleración.

2. Mochila 0/1: menor peso contra valor/peso

Para una capacidad de 10 kg se evaluaron tres objetos indivisibles. En el método 1 se ordenan por peso ascendente; en el método 2 por densidad valor/peso descendente. En ambos casos se incorpora el siguiente objeto solo si cabe en la capacidad restante.

Objeto	Peso (kg)	Valor	Valor/peso
A	2	2	1.00
B	4	8	2.00
C	6	18	3.00

Criterio	Objetos elegidos	Peso usado	Valor total
Menor peso	A, B	6	10
Mayor valor/peso	C, B	10	26

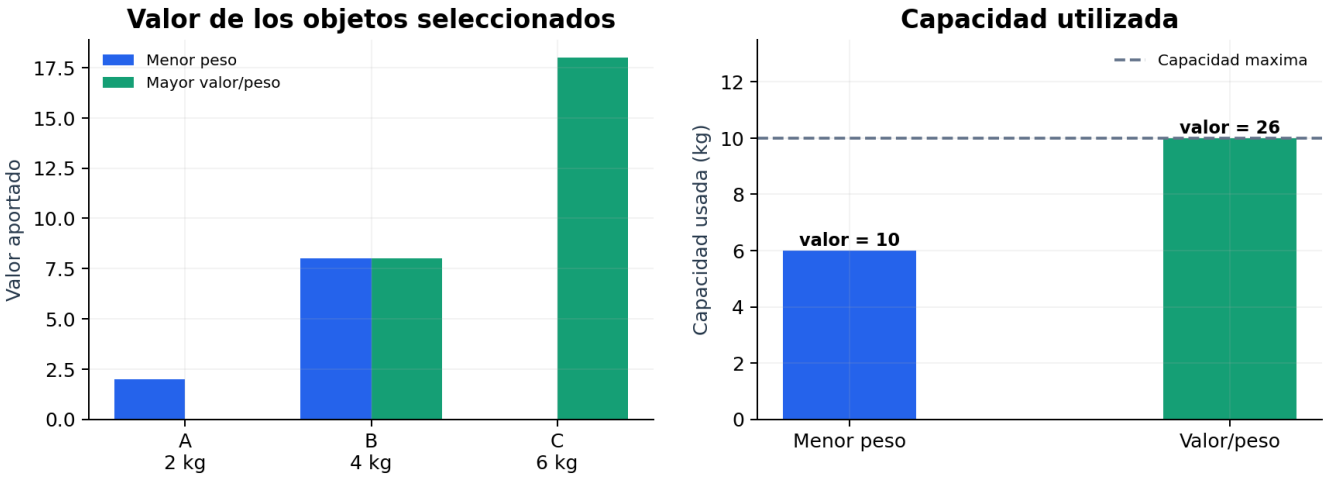


Figura 2. Selecciones y aprovechamiento de la capacidad.

Análisis: seleccionar primero los más ligeros produce valor 10; priorizar densidad da valor 26. La primera estrategia compromete capacidad con objetos poco valiosos. Esta instancia demuestra que menor peso puede ser peor que valor/peso. La heurística valor/peso tampoco garantiza el óptimo general de la mochila 0/1.

3. Búsqueda local: 2-opt para TSP

Se generó un conjunto fijo de 25 ciudades y se realizaron 40 ensayos por método inicial. Para cada ensayo se comparó una permutación aleatoria contra vecino más cercano (ciudad inicial aleatoria). 2-opt evalúa todas las inversiones válidas de segmentos y acepta la mejor reducción por iteración hasta alcanzar un óptimo local.

Métrica (media)	Inicio aleatorio	Vecino más cercano
Costo inicial	1383.54	572.00
Número de mejoras	19.25	4.10
Costo final	507.99	500.45

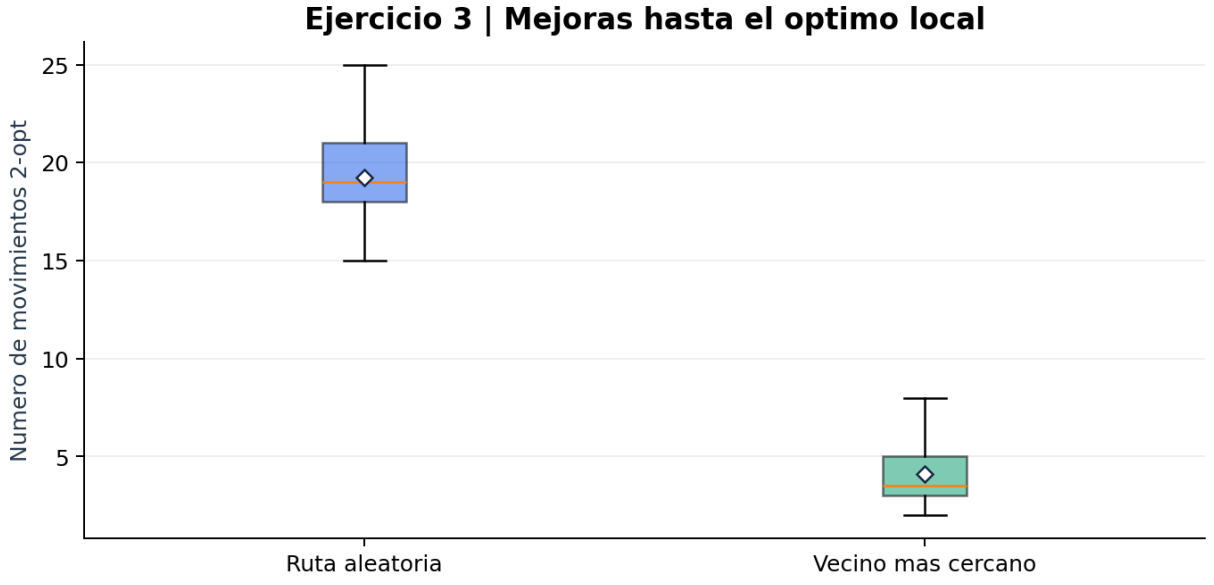


Figura 3. Distribución de mejoras hasta el óptimo local.

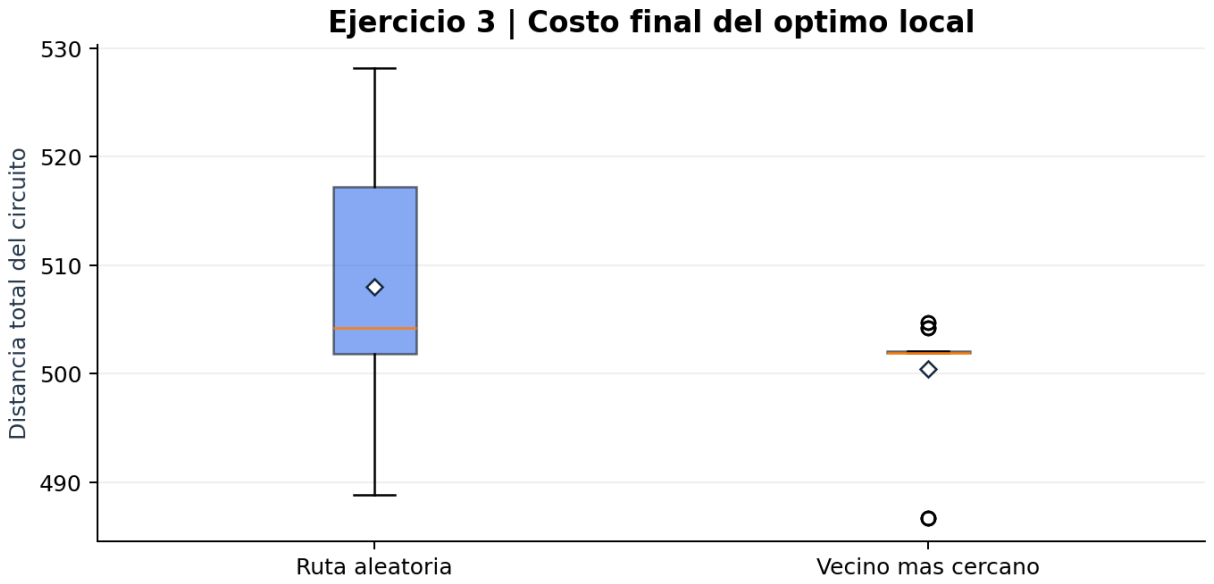


Figura 4. Distancias finales tras búsqueda local con 2-opt.

Análisis: en esta muestra, vecino más cercano requirió menos mejoras que el inicio aleatorio (4.10 frente a 19.25, en promedio). La menor distancia final promedio correspondió a vecino más cercano. El número de mejoras cuenta movimientos aceptados, no tiempo de CPU. Un óptimo local no implica óptimo global: diferentes rutas iniciales pueden converger a circuitos distintos.

4. Recocido simulado: ajuste del enfriamiento

En el mismo escenario de 25 ciudades se compararon 25 ejecuciones por calendario, de 4500 iteraciones cada una. Se usó el mismo punto de partida de cada ensayo para ambos calendarios, con T inicial = 40 y T final = 0.1. Los vecinos son movimientos 2-opt; las soluciones peores pueden aceptarse con probabilidad exp(-Δ/T). Siempre se conserva la mejor ruta encontrada.

Enfriamiento	Costo final medio	Tiempo medio (s)	Desv. costo
Lineal	514.97	0.0306	14.99
Exponencial	507.04	0.0318	10.38

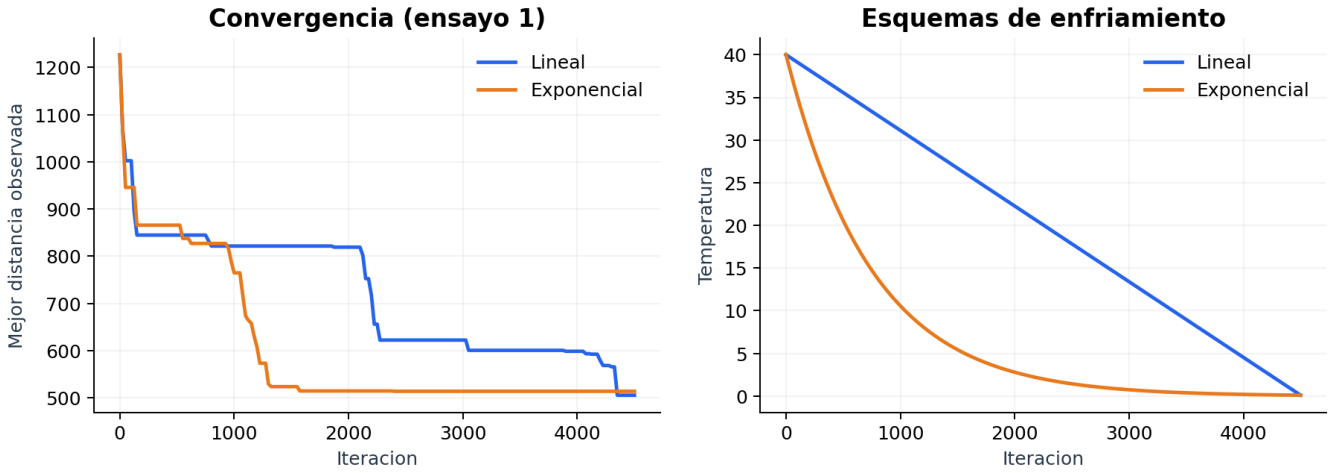


Figura 5. Evolución del mejor costo y temperatura de un ensayo comparable.

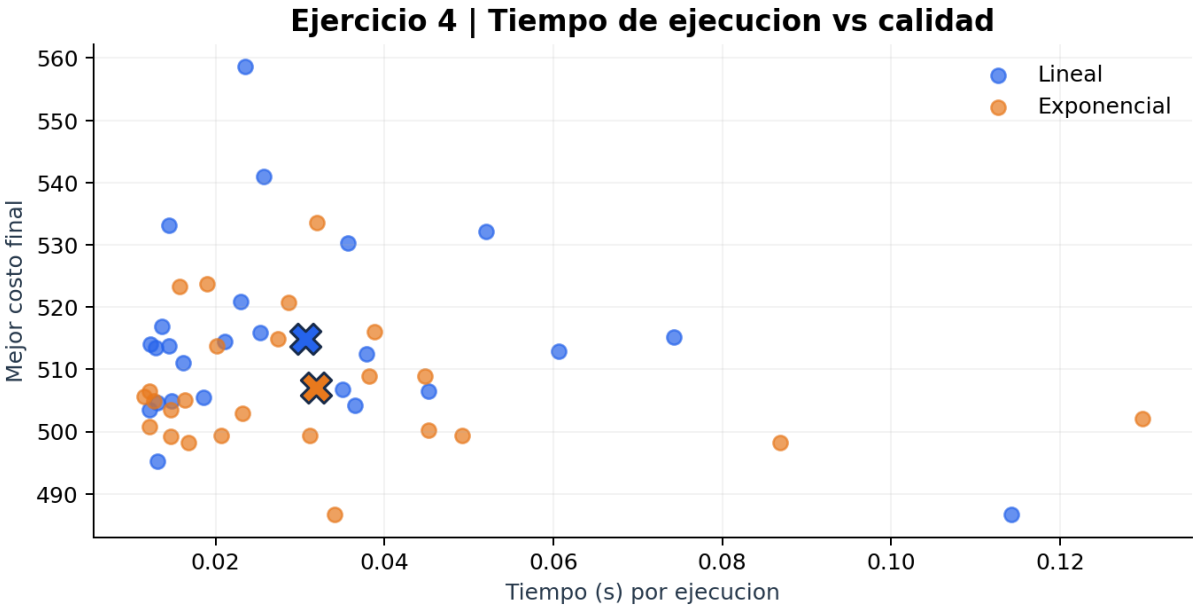


Figura 6. Tiempo real frente a costo final en cada réplica; la X señala la media.

Análisis: la menor distancia media correspondió al enfriamiento exponencial, mientras que el menor tiempo medio se observó con el enfriamiento lineal. El lineal conserva temperaturas relativamente elevadas durante más iteraciones; el exponencial disminuye más proporcionalmente al inicio. Ambos ejecutan el mismo número de iteraciones; las diferencias de tiempo incluyen ruido del sistema y costos de operaciones específicas. No se garantiza superioridad universal.

5. Razón de aproximación de MST

Se generaron exactamente 100 instancias aleatorias independientes de 9 ciudades con distancias euclidianas. Para cada instancia se obtuvo el óptimo global con Held-Karp, luego una ruta MST (Prim + preorden + atajos) y se aplicó 2-opt a esa ruta. También se ejecutaron los dos inicios de búsqueda local y los dos esquemas de recocido simulado sobre las mismas instancias; en recocido se usaron 2,500 iteraciones por ejecución.

Método	Costo medio	Razón media	Razón máxima
MST preorden	307.90	1.151	1.419
MST + 2-opt	268.06	1.003	1.066
Local aleatorio	267.75	1.002	1.076
Local vecino	267.69	1.002	1.031
Recocido lineal	267.20	1.000	1.000
Recocido exp.	267.20	1.000	1.000

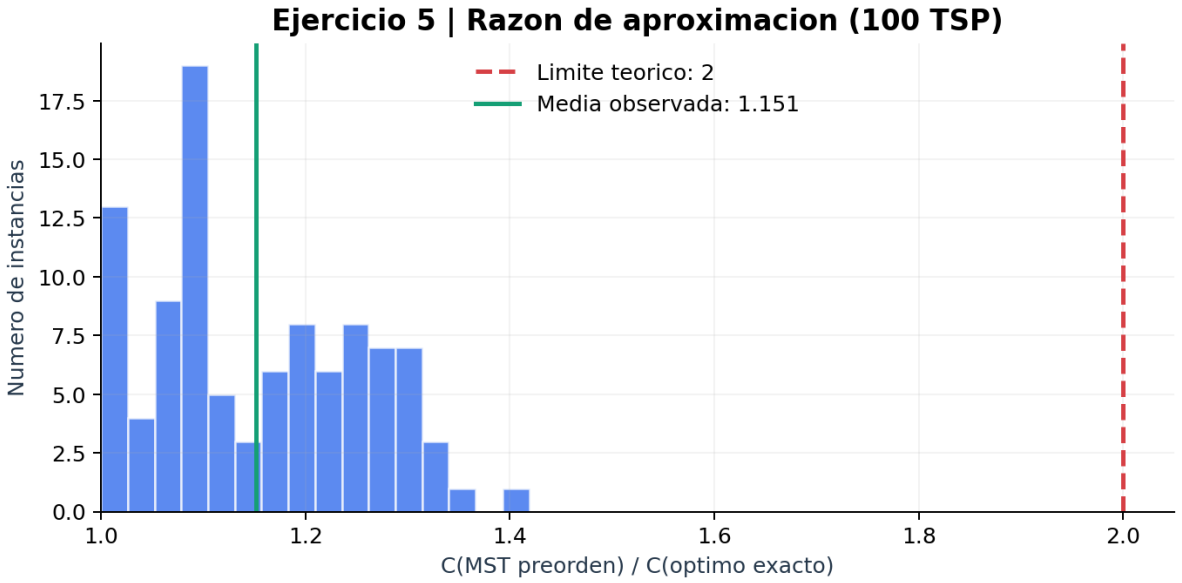


Figura 7. Distribución de C(MST)/C(óptimo) y referencia teórica en 2.

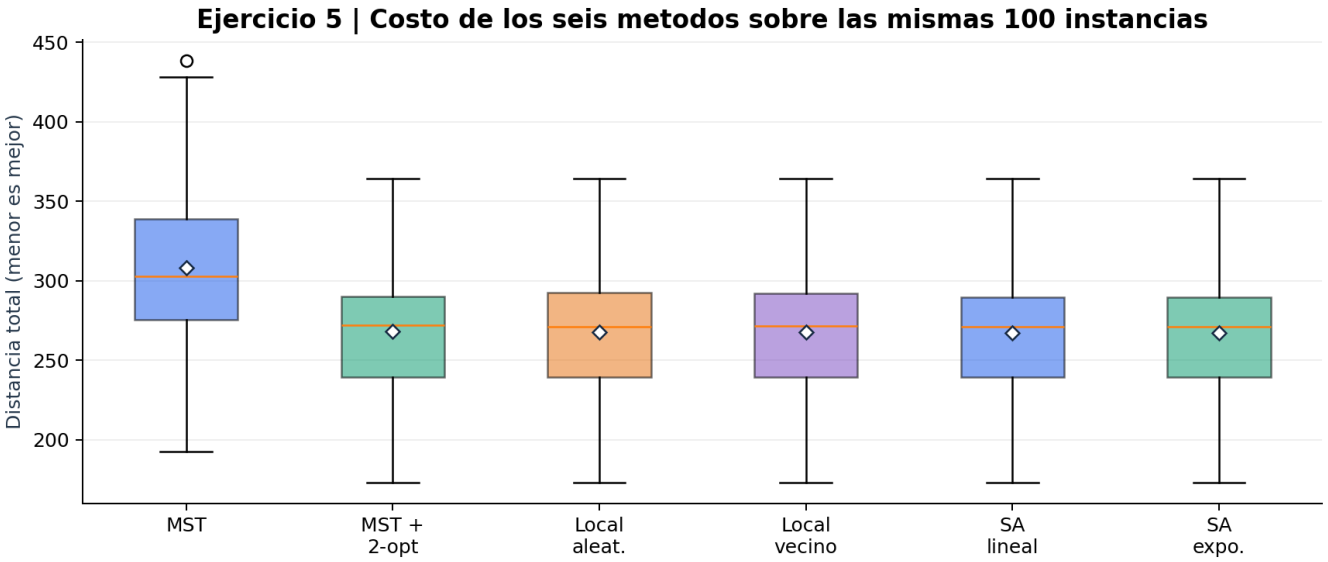


Figura 8. Costos reales de los seis métodos en las 100 instancias.

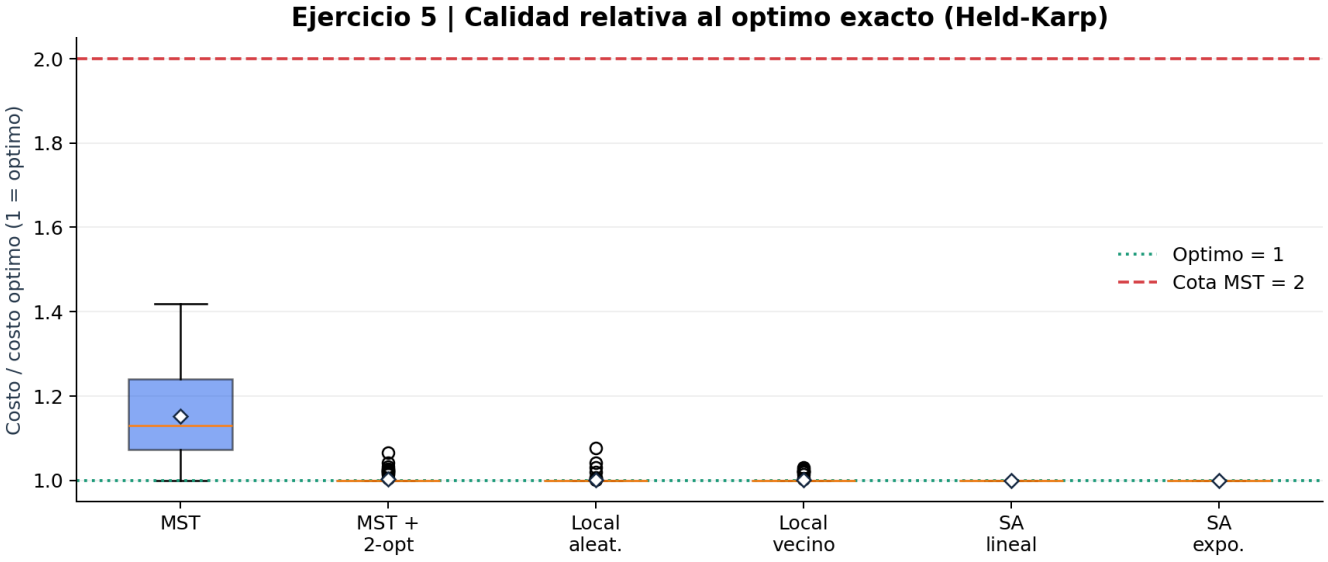


Figura 9. Razones respecto del óptimo exacto, para comparación normalizada.

Análisis: la razón media de MST fue 1.151, y la máxima 1.419, por debajo o igual al límite teórico de 2. Agregar 2-opt redujo el costo medio de 307.90 a 268.06, equivalente a una reducción de 12.9%. La cota de 2 es una garantía de peor caso para el TSP métrico, no una predicción de las razones típicas. La mejora posterior no puede aumentar el costo debido a que 2-opt solo acepta cambios estrictamente favorables.

Conclusiones, limitaciones y reproducibilidad

Los resultados muestran cómo el paralelismo real depende de los costos de administración; cómo la regla greedy elegida altera el resultado en mochila 0/1; y cómo la solución inicial y el enfriamiento afectan las heurísticas para el TSP. El MST preorden proporciona una garantía matemática para distancias métricas y puede mejorarse con búsqueda local.

Limitaciones: las mediciones de tiempo varían según el equipo y los procesos en segundo plano. Las comparaciones empíricas no prueban que un método sea superior en todas las instancias. Los recocidos son estocásticos y las conclusiones corresponden a las semillas, tamaños y parámetros usados. El límite 2 del MST requiere distancias métricas (desigualdad triangular).

Reproducibilidad: ejecutar **python main.py** desde la raíz del repositorio. Las semillas están fijadas en el código. Los datos completos se guardan en **resultados/**, las nueve visualizaciones en **graficas/** y el reporte en **reporte_final.pdf**. Las pruebas automáticas se ejecutan con **python -m unittest discover -s tests -v**.

Referencias conceptuales: Ley de Amdahl (aceleración paralela); heurística 2-opt (búsqueda local TSP); recocido simulado con criterio de Metropolis; aproximación doble del árbol mínimo para TSP métrico; programación dinámica Held-Karp para TSP exacto.